Activer Flash Attention dans SpatialLM

Guide court pour tester sur une machine avec GPU compatible

1. Vérifier le GPU

```
nvidia-smi --query-gpu=name,compute_cap --format=csv
```

Il faut une capacité de calcul **8.0 ou plus** (Ampere : RTX 30xx/40xx, A100...). Sinon, Flash Attention n'est pas supporté.

2. Installer Flash Attention

Dans l'environnement où SpatialLM fonctionne déjà (torch 2.4.1 avec CUDA 12.4) :

```
pip install ninja
pip install flash-attn --no-build-isolation
```

Si l'installation compile et que la RAM est limitée : `MAX_JOBS=4 pip install flash-attn --no-build-isolation`. **Ne pas réinstaller ni changer torch après cette étape.**

Vérifier :

```
python -c "import flash_attn; print(flash_attn.__version__)"
```

3. Modifier le code

Fichier : `spatiallm/model/sonata_encoder.py`

Aux **lignes 319, 526 et 826**, remplacer :

```
enable_flash=False      ->      enable_flash=True
```

À la main (3 lignes), ou en une commande :

```
sed -i 's/enable_flash=False/enable_flash=True/' spatiallm/model/sonata_encoder.py
```

Les étapes 2 et 3 vont ensemble : sans installation, le modèle ne se charge pas ; sans modification, Flash reste inactif.

4. Relancer l'inférence

```
python inference.py -p chemin/vers/clean.ply -o layout_flash.txt --seed 42
```

ou l'interface habituelle : `streamlit run pipeline_gui.py`

Pour comparer, remettre `enable_flash=False`, relancer sur le même fichier avec le même seed, puis comparer le temps et la mémoire GPU (`nvidia-smi`). Les textes peuvent différer légèrement (calcul en float16) : ce n'est pas une erreur.

En cas de problème

Erreur	Correctif
`undefined symbol ...` à l'import de flash_attn ou torch_scatter	torch a changé après l'installation. Remettre torch 2.4.1+cu124, puis réinstaller flash-attn.
`Make sure flash_attn is installed`	Refaire l'étape 2.
Échec de compilation	Vérifier `nvcc --version` (12.4) et utiliser MAX_JOBS=4.

Retour arrière : remettre `enable_flash=False`. Merci de renvoyer le résultat (temps, mémoire, ou le message d'erreur complet). Ces commandes n'ont pas encore été exécutées sur un GPU Ampere.